

04. Mapa completo del código

AI Dataset Foundry
Versión 0.2.0
2026-09-10
Fuente: 04-code-map.md

04. Mapa completo del código

Inventario jerárquico

Ruta	Responsabilidad / consumidor	Estado e importancia
src/ai_dataset_foundry/models.py	SourceInfo, DocumentRecord, Provenance, QualityResult, ChunkRecord; todo el pipeline	Activo, crítico
config.py	modelos ChunkConfig, QualityConfig, DedupConfig, BuildConfig; CLI/API/pipeline	Activo, crítico
pipeline.py	build_dataset, orquestación, manifest y SQLite	Activo, crítico
connectors/router.py	ingest, load_path, despacho por locator/extensión	Activo, crítico
connectors/text.py	_record, load_text, load_json, load_csv	Activo
connectors/pdf.py, docx.py, html.py	extracción opcional local	Activo con extras
connectors/web.py	load_url, fetch único HTTP(S) y extracción	Activo con extra; delicado por red
connectors/git.py	load_git, _load_repo, clone shallow temporal	Activo; delicado por subprocess/red
connectors/base.py	ABC Connector, no instanciada por implementaciones actuales	Experimental/no utilizado directamente
processors/normalize.py, clean.py	canonicalización Unicode/espacios y controles	Activo
processors/chunk.py	_fixed, _pack, chunk_text	Activo, crítico
processors/dedup.py	_tokens, simhash, hamming, Deduplicator	Activo, crítico; costo $O(n^2)$ aproximado
processors/privacy.py, quality.py	detect_sensitive, assess_quality	Activo; control heurístico
exporters/*	export_records, JSONL/TXT/Parquet	Activo
storage/sqlite_store.py	_SCHEMA, write_sqlite	Activo, crítico para catálogo
utils/hashing.py	hashes e IDs deterministas	Activo, crítico
cli.py	comandos build, stats, validate, serve, desktop	Activo
webapp.py	create_app, _decode_list, _save_upload; rutas UI/API	Activo; superficie local
desktop.py, launcher.py	puerto libre, servidor thread, ventana pywebview	Activo Windows
ui/index.html	cliente de la API local	Activo
android/	MainActivity, DatasetBuilder, prueba JUnit y build Android	Activo, release mínima independiente
tests/	9 pruebas Python en 7 archivos	Activo, cobertura parcial
scripts/doctor.py	prerrequisitos	Activo
scripts/smoke.py	build E2E sobre muestra sintética	Activo
scripts/verify_docs.py	enlaces, versión, workflows y pins	Activo
scripts/generate_system_pdfs.py	fuelle Markdown a PDF + chequeos	Activo, documental
.github/workflows/	CI, Security, Pages y Release	Activo, crítico
site/	landing estática de Pages	Activo
docs/	manual temático previo + esta documentación integral	Activo
dist/, work/	artefactos reproducidos/locales; ignorados parcialmente	Generado, no fuente

Dependencias y llamadas clave

cli.build y webapp.build crean BuildConfig y llaman build_dataset. Éste llama connectors.ingest, luego normalize_text → clean_text → chunk_text → Deduplicator.is_duplicate → assess_quality, construye ChunkRecord, llama export_records y opcionalmente write_sqlite.

`desktop.main` aloja `create_app`. Android no llama al núcleo Python.

Archivos aparentemente duplicados: `site/index.html` (landing pública) y `src/.../ui/index.html` (aplicación) son propósitos distintos. `Connector` es una abstracción sin adopción actual. `launcher.py` existe para empaquetado y delega completamente a escritorio.