

05. Referencia técnica

AI Dataset Foundry
Versión 0.2.0
2026-09-10
Fuente: 05-technical-reference.md

05. Referencia técnica

Configuración y contratos

Símbolo	Firma/campos y propósito	Validación / efecto
ChunkConfig	strategy, size=1200, overlap=120	estrategia literal; tamaño 100..100000; overlap 0..20000
QualityConfig	min_chars=80, max_control_ratio=.02, reject_secrets=False	rangos Pydantic
DedupConfig	enabled, near_duplicate, simhash_distance=3	distancia 0..32
BuildConfig	inputs, out_dir, formats, recursive, write_sqlite y subconfigs	from_yaml(path) puede lanzar I/O, YAML o ValidationError
DocumentRecord	id, text, source, metadata, source_sha256	salida común de adquisición
ChunkRecord.to_dict()	() -> dict	serialización recursiva con asdict

Funciones del núcleo

Símbolo	Entrada → retorno	Llama / efectos / riesgos
build_dataset(config)	BuildConfig → (list[ChunkRecord], dict)	ingiere, transforma y escribe artefactos; aísla sólo errores de locator
ingest(locator, recursive=True)	texto → documentos	red/Git/FS; FileNotFoundError; directorios omiten extensiones desconocidas
load_path(path)	Path → documentos	despacho por extensión; desconocida devuelve []
chunk_text(text, strategy, size, overlap=0)	texto → piezas	estrategia desconocida cae a párrafos; normalmente Pydantic lo evita
Deduplicator.is_duplicate(text)	texto → bool	muta sets/lista; exacto y SimHash; memoria por build
assess_quality(text, config)	texto → QualityResult	marca/rechaza por longitud, controles y posible secreto
export_records(records, out_dir, formats)	registros → rutas	crea directorio; formato inválido ValueError; salida parcial posible
write_sqlite(records, manifest, path)	→ None	crea esquema, borra tablas y reinserta en transacción SQLite
sha256_bytes/text/file	datos → hex SHA-256	lectura de archivo puede fallar
stable_id(prefix, *parts)	componentes → ID	usa separador U+001F y 20 hex; riesgo teórico de colisión por truncado

Los loaders locales generan uno o varios DocumentRecord: JSON array/JSONL y CSV generan registros por elemento/fila; PDF por página; DOCX combina párrafos/tablas; HTML y web extraen texto visible; Git reetiqueta los registros con repo y ruta. Consulte [Conectores](#) para límites detallados.

API y comandos

Interfaz	Contrato
GET /	HTML embebido; 200 o error de lectura del recurso
GET /api/health	{"status": "ok", "version": "0.2.0"}
POST /api/build	multipart: files, locators JSON, formats JSON, chunk settings, reject_secrets; 200 resultado, 400 validación/build, 413 carga
GET /api/runs/{run_id}/artifacts/{name}	descarga; 400 ruta inválida, 404 ausente
foundry build	pipeline por argumentos o YAML
foundry stats	métricas simples de JSONL
foundry validate	valida YAML sin ingerir

Interfaz	Contrato
foundry serve/desktop	UI localhost / ventana Windows

No hay variables de entorno consumidas por el código. Constantes relevantes: RUNS_DIR, UI_FILE, MAX_UPLOAD_BYTES=50 MiB, _ALLOWED_EXTENSIONS, _SECRET_PATTERNS, _SCHEMA. Eventos/estados formales no existen; estados observables son documento cargado, chunk duplicado/rechazado/aceptado y error de ingestión.

Códigos y razones

Razones de calidad: too_short, too_many_control_characters, possible_secret, y flags informativos flag:contains_email. Errores de extras incluyen mensajes ... requires: uv sync --extraGit propaga CalledProcessError; la API lo transforma a HTTP 400 sin tipado estable.