

07. Base de datos y persistencia

AI Dataset Foundry
Versión 0.2.0
2026-09-10
Fuente: 07-database.md

07. Base de datos y persistencia

El mecanismo persistente implementado es SQLite, archivo `dataset.sqlite`, escrito con `sqlite3`. No hay servidor, ORM, migraciones versionadas, seeds, vistas, triggers, procedimientos, cifrado ni backups automáticos. `PRAGMA journal_mode=WAL` se solicita al crear la conexión. Cada build sobre la misma ruta elimina y reemplaza filas; los originales permanecen fuera de la DB.

```
erDiagram
    DATASET_META {
        TEXT key PK
        TEXT value
    }
    CHUNKS {
        TEXT id PK
        TEXT document_id
        TEXT text
        TEXT source_kind
        TEXT source_locator
        TEXT source_title
        TEXT source_license
        TEXT metadata_json
        TEXT source_sha256
        TEXT content_sha256
        REAL quality_score
        TEXT quality_reasons_json
    }
```

No existe FK entre tablas: `dataset_meta` describe el conjunto y `chunks` almacena filas independientes. `document_id` está indexado pero no referencia una tabla de documentos.

Diccionario de datos

Tabla.campo	Tipo/regla	Origen y uso
<code>dataset_meta.key</code>	TEXT PK	actualmente manifest
<code>dataset_meta.value</code>	TEXT NOT NULL	JSON del manifest
<code>chunks.id</code>	TEXT PK	<code>stable_id("chunk", document_id, index, content_hash)</code>
<code>document_id</code>	TEXT NOT NULL, índice	ID del DocumentRecord
<code>text</code>	TEXT NOT NULL	fragmento limpio; puede contener información sensible no detectada
<code>source_kind</code>	TEXT NOT NULL, índice	tipo de conector
<code>source_locator</code>	TEXT NOT NULL	ruta/URL/repo; puede revelar ubicaciones locales
<code>source_title, source_license</code>	TEXT nullable	metadatos disponibles; licencia suele requerir curación
<code>metadata_json</code>	TEXT NOT NULL	JSON específico de conector + <code>chunk_index</code>
<code>source_sha256</code>	TEXT NOT NULL	hash de bytes de la fuente
<code>content_sha256</code>	TEXT NOT NULL, índice	hash del chunk transformado
<code>quality_score</code>	REAL NOT NULL	0..1 según reglas actuales
<code>quality_reasons_json</code>	TEXT NOT NULL	razones/flags JSON

`write_sqlite` es el único escritor. El contexto de conexión confirma al salir y revierte ante excepción. No hay lecturas en la aplicación actual: SQLite funciona como catálogo interoperable. Respaldo/recuperación: no documentado; al ser derivado, se recomienda conservar fuentes/config/manifest y regenerar, o copiar el archivo con herramientas SQLite seguras. Los hashes detectan identidad, no prueban autoría ni integridad criptográfica del conjunto porque no hay firma.