

08. Flujo de datos

AI Dataset Foundry
Versión 0.2.0
2026-09-10
Fuente: 08-data-flow.md

08. Flujo de datos

Origen a consumo

Etap	Datos	Validación/transformación	Riesgo
Entrada	rutas, URLs, repos, uploads	existencia, extensión/router; JSON/CSV/parsers	fuentes hostiles, SSRF si se expone la API, archivos grandes
Documento	texto + source + metadata + SHA	adaptador específico	pérdida de layout/encoding/licencia
Normalización	Unicode NFKC, saltos, espacios	regex y unicodedata	cambios semánticos en casos Unicode delicados
Limpieza	NUL, controles, líneas repetidas	reglas deterministas	falsos positivos en contenido intencional
Chunking	fragmentos	estrategia/tamaño	pérdida de contexto; overlap sólo fixed
Dedup	SHA exacto + SimHash	umbral configurable	falsos positivos, orden, costo O(n²)
Calidad	longitud/controles/secreto/email	score y razones	detector incompleto; email no se rechaza
Salida	JSONL/TXT/Parquet/SQLite/manifest	serializers	artefactos parciales y datos sensibles persistentes

```
flowchart LR
  A[Bytes/red] --> B[Texto + SHA fuente]
  B --> C[Texto canónico]
  C --> D[Chunks]
  D --> E{duplicado?}
  E -- sí --> F[contador descartado]
  E -- no --> G{calidad aceptada?}
  G -- no --> H[razones agregadas]
  G -- sí --> I[ChunkRecord + hash contenido]
  I --> J[Archivos y SQLite]
  F --> M[Manifest]
  H --> M
  J --> M
```

Los datos enviados a servicios externos son únicamente las solicitudes HTTP a la URL elegida y el clone Git al host elegido. No hay telemetría ni API de IA. Pages/CI operan sobre el repositorio público, no sobre corpus locales.

Datos presentados al usuario: conteos, rechazos, errores de ingestión y nombres descargables; los artefactos contienen el texto completo. La UI guarda uploads y outputs bajo work/ui-runs; no se observa política automática de expiración. Rutas/URLs, emails y posibles secretos pueden quedar en outputs o manifest. reject_secrets sólo filtra patrones limitados; la autorización, minimización, retención y borrado corresponden al operador.

Ejemplo seguro: examples/sample.txt → DocumentRecord con hash → chunks aceptados → dataset.jsonl y dataset.sqlite → manifest.json. La prueba smoke confirma este camino sin contenido privado.