

09. APIs e integraciones

AI Dataset Foundry

Versión 0.2.0

2026-09-10

Fuente: 09-apis-and-integrations.md

09. APIs e integraciones

API HTTP local

Base predeterminada: `http://127.0.0.1:8765`. Sin autenticación, autorización, CORS configurado, CSRF token ni versionado de URL; no debe exponerse en red.

Método/ruta	Solicitud	Respuesta / errores
GET /	sin parámetros	frontend HTML
GET /api/health	sin parámetros	200, estado y versión
POST /api/build	multipart; files*, locators JSON, formats JSON, chunk_strategy, chunk_size, overlap, reject_secrets	200 con run/conteos/artefactos; 400 datos/build; 413 >50 MiB por archivo
GET /api/runs/{run_id}/artifacts/{name}	segmentos simples	archivo; 400 traversal/ID, 404 ausente

```
curl -F 'files=@examples/sample.txt;type=text/plain' \
-F 'locators=[]' -F 'formats=["jsonl"]' \
http://127.0.0.1:8765/api/build
```

Respuesta abreviada: `{"run_id": "...", "documents": 1, "chunks": n, "artifacts": [...]}`. No existe OpenAPI pública porque /docs y /redoc están deshabilitados, aunque FastAPI puede mantener /openapi.json por defecto (inferencia basada en configuración).

Integraciones externas

- **HTTP(S)**: Requests realiza una descarga de página con User-Agent propio; Trafilatura o BS4 extraen HTML. Timeout/reintentos/límites/robots: revisar `connector s/web.py`; no hay crawler.
- **Git**: ejecutable externo, clone shallow y temporal. Autenticación utiliza el entorno de Git del usuario; no almacena tokens.
- **Documentos**: pypdf y python-docx; HTML local con BS4.
- **Parquet**: PyArrow con compresión Zstd.
- **UI/desktop**: FastAPI, Uvicorn, multipart y pywebview en loopback.
- **GitHub**: Actions para CI, auditoría, Pages y release; Dependabot para actualizaciones.

No hay webhooks, OAuth, proveedores de modelos, bases remotas ni límites de proveedor modelados. Los códigos HTTP remotos no se exponen como contrato propio; excepciones se registran en manifest (CLI) o terminan como 400 (API).