

10. Configuración

AI Dataset Foundry
Versión 0.2.0
2026-09-10
Fuente: 10-configuration.md

10. Configuración

La configuración canónica es BuildConfig, creada por CLI/API o YAML (examples/config.yaml). No se leen variables de entorno. Los secretos no deben almacenarse en configuración; una URL con credenciales terminaría en manifest.

Campo	Default	Obligatorio/rango	Consecuencia
inputs	[]	al ejecutar debe haber al menos uno	vacío desde CLI/API se rechaza; llamada directa puede producir dataset vacío
out_dir	work/dataset	ruta escribible	se crean/reemplazan artefactos con nombres fijos
formats	[jsonl]	jsonl/txt/parquet	parquet requiere extra
recursive	true	bool	recorre subdirectorios
write_sqlite	true	bool	crea catálogo SQLite
chunk.strategy	paragraph	paragraph/fixed/sentence/markdown	cambia límites/contexto
chunk.size	1200	100..100000	tamaño objetivo en caracteres
chunk.overlap	120	0..20000; efectivo en fixed	se limita internamente a size-1
quality.min_chars	80	>=1	fragmentos menores se rechazan
quality.max_control_ratio	.02	0..1	controles excesivos se rechazan
quality.reject_secrets	false	bool	API usa true por defecto
dedup.enabled	true	bool	desactivarlo conserva copias
dedup.near_duplicate	true	bool	activa SimHash
dedup.simhash_distance	3	0..32	umbral mayor descarta más

```
inputs:
  - examples/sample.txt
out_dir: work/example
formats: [jsonl, txt]
recursive: true
write_sqlite: true
chunk: {strategy: paragraph, size: 1200, overlap: 120}
quality: {min_chars: 80, max_control_ratio: 0.02, reject_secrets: true}
dedup: {enabled: true, near_duplicate: true, simhash_distance: 3}
```

No existen perfiles formales dev/test/prod ni feature flags externas. Las diferencias dependen del extra instalado y del punto de entrada. Configuración incorrecta puede descartar demasiado, consumir memoria/tiempo, sobrescribir outputs derivados o descargar fuentes no autorizadas. Valide con foundry validate y use un out_dir nuevo para corridas comparables.