

17. Resumen ejecutivo

AI Dataset Foundry
Versión 0.2.0
2026-09-10
Fuente: 17-executive-summary.md

17. Resumen ejecutivo

AI Dataset Foundry convierte documentos, sitios y repositorios autorizados en datasets trazables para IA. Su valor no es sólo leer formatos: conserva procedencia, aplica transformaciones reproducibles, separa piezas aceptadas/rechazadas y entrega formatos interoperables con manifest auditable.

La versión 0.2.0 ofrece CLI, web local, Windows y Android offline reducido. El núcleo Python cubre texto/código, JSON/JSONL, CSV y, con extras, PDF, DOCX, HTML, web, Git y Parquet. Exporta JSONL, TXT, SQLite y Parquet. CLI/web/escritorio reutilizan el pipeline; Android es independiente.

Fortalezas

- Privacidad local y ausencia de telemetría observada.
- Provenance con hashes e IDs estables.
- Fallos de adquisición aislados y manifest explícito.
- Distribución multiplataforma y CI reproducible.
- Límites honestos: preparación no equivale a entrenamiento, verdad ni licencia.

Riesgos y próximos pasos

Es alpha/laboratorio, no servicio compartido. La API sin auth sólo debe escuchar en loopback. Parsers/red no están aislados ni presupuestados; el detector de secretos es heurístico; faltan retención, observabilidad, RBAC, DLP y mayor cobertura. Gobierno humano sigue siendo obligatorio.

Antes de producción: aislar entradas, endurecer red, formalizar políticas de datos, añadir staging atómico y ampliar pruebas/benchmarks. Después: actualización incremental/extracción avanzada y adaptadores específicos para pretraining/SFT/RAG/evals, siempre con evidencia CI.