

Documentación integral de AI Dataset Foundry

AI Dataset Foundry
Versión 0.2.0
2026-09-10
Fuente: README.md

Documentación integral de AI Dataset Foundry

AI Dataset Foundry es una factoría local-first que convierte fuentes heterogéneas en corpus auditables para pretraining, fine-tuning, RAG y evaluación. Esta carpeta reúne una lectura verificable del repositorio para personas no técnicas, desarrollo, operación, auditoría y agentes de IA.

Corte del análisis: 2026-09-10. **Versión:** 0.2.0. **Commit base:** 322e298. **Estado:** completa y verificada contra el código; las inferencias y ausencias se señalan expresamente.

Índice y estado

Documento	Finalidad	Estado
01. Descripción general	propósito, actores y alcance	Verificado
02. Instalación y ejecución	preparar, ejecutar y probar	Verificado
03. Arquitectura	componentes, secuencias y despliegue	Verificado
04. Mapa del código	inventario y responsabilidades	Verificado
05. Referencia técnica	contratos, símbolos, rutas y errores	Verificado
06. Explicación profunda	recorrido interno del pipeline	Verificado
07. Base de datos	esquema SQLite y persistencia	Verificado
08. Flujo de datos	entradas, transformaciones y salidas	Verificado
09. APIs e integraciones	HTTP local y proveedores	Verificado
10. Configuración	YAML, CLI y valores	Verificado
11. Seguridad	controles y superficie de ataque	Verificado
12. Pruebas y calidad	CI, pruebas y brechas	Verificado
13. Despliegue y operación	releases, Pages y runbook	Verificado
14. Troubleshooting	diagnóstico práctico	Verificado
15. Riesgos y deuda	hallazgos priorizados	Verificado
16. Glosario	lenguaje técnico y del dominio	Verificado
17. Resumen ejecutivo	lectura para decisión	Verificado
18. Guía de incorporación	itinerario para contribuir	Verificado
19. Trazabilidad	función a implementación y prueba	Verificado
PDF	versiones generadas desde Markdown	Generado y revisado

Convenciones

- **Comprobado:** visible en código, manifest, prueba o workflow.
- **Inferencia basada en el código:** conclusión razonable no declarada como contrato.
- **No documentado en el repositorio:** no existe evidencia suficiente.
- Rutas, nombres de símbolos y comandos se conservan literalmente; no se reproducen secretos.

Pendientes de validación humana

- Política formal de retención/borrado, SLA, soporte LTS y propietario operativo: no documentados.
- Modelo jurídico para derechos de cada corpus, clasificación de PII y base legal: depende del operador.
- Carga, rendimiento máximo y seguridad de parsers ante documentos hostiles: requieren pruebas aisladas.
- La UI y el host Windows no son un servicio multiusuario ni un sandbox.

Los PDF se regeneran con `python scripts/generate_system_pdfs.py`; Markdown es la única fuente editable.